

Conteo de granos de soja mediante detección de objetos entrenada con datos sintéticos auto-etiquetados

Lic. Daniela S. Putrino
Especialización en Inteligencia Artificial (CEIA)
Facultad de Ingeniería, Universidad de Buenos Aires
Buenos Aires, Argentina

Resumen—El conteo de granos de soja para control de calidad es una tarea repetitiva y subjetiva cuando se realiza de forma manual. Su automatización por aprendizaje profundo está limitada por la disponibilidad de imágenes etiquetadas a nivel de instancia, cuya anotación manual es costosa. Este trabajo propone un *prototipo funcional* que resuelve el cuello de botella generando un dataset sintético con *ground truth* automático: a partir de granos reales segmentados se componen escenas mediante *alpha compositing* y *domain randomization*, con control de oclusión, y la etiqueta de cada grano se escribe de forma determinista durante la composición. Sobre ese dataset se realiza *fine-tuning* de un detector pre-entrenado YOLOv8. El modelo nano alcanza $\text{mAP}@0.5 = 0.995$, $\text{mAP}@0.5:0.95 = 0.979$ y error de conteo (MAE) = 0 en validación in-distribution, con ~ 13 ms de inferencia por imagen y solo 3,0 M de parámetros. El sistema se despliega como un servicio web (FastAPI) que devuelve el conteo, una bandera de confianza y la imagen anotada. Se discute de forma explícita la brecha *sim-to-real* como límite del enfoque.

Index Terms—visión por computadora, detección de objetos, datos sintéticos, YOLOv8, domain randomization, conteo de objetos, agricultura de precisión.

I. INTRODUCCIÓN

El control de calidad de granos de soja requiere **cuantificar y localizar** cada grano en una muestra. Hecho a mano, el conteo es lento, fatigante y subjetivo: dos operarios pueden reportar valores distintos sobre la misma bandeja. La visión por computadora basada en *deep learning* permite automatizar la tarea, pero su principal limitación práctica no es el modelo sino la **escasez de datos etiquetados a nivel de instancia**: anotar miles de imágenes caja por caja es costoso y no cubre la variabilidad real.

Objetivo. Diseñar y validar un prototipo de detección y conteo de granos de soja que evite la anotación manual, mediante la *generación de datos sintéticos auto-etiquetados* y el *fine-tuning* de un modelo pre-entrenado.

Antecedentes recientes. La automatización del conteo de soja por visión es un problema activo. Trabajos recientes (≤ 8 años) aplican redes profundas al conteo de vainas y granos a partir de imágenes de campo y laboratorio, con arquitecturas tipo *transformer-CNN* para conteo denso [6], y otros combinan redes profundas con adaptación de dominio para contar vainas y semillas en campo y laboratorio [7]. El conjunto de imágenes individuales de soja empleado en este trabajo proviene de un dataset público reciente [1]. A diferencia de

esos trabajos, que anotan datos reales, nuestro aporte genera un dataset sintético con *ground truth* exacto y hace *fine-tuning* de un detector pre-entrenado liviano, empaquetado como servicio desplegable.

II. METODOLOGÍA, DISEÑO Y DESARROLLO

El sistema tiene tres bloques: (1) generación de datos sintéticos, (2) entrenamiento y (3) inferencia/despliegue.

II-A. Extracción y estandarización del grano

Se parte de imágenes individuales de granos reales (5513 imágenes de 227×227 , cinco categorías de calidad) [1]. Cada grano se aísla del fondo por umbralizado de Otsu [3], que elige el umbral t que maximiza la varianza inter-clase $\sigma_b^2(t)$. La máscara binaria se asigna al **canal alfa** (RGBA) y se recorta a su *bounding box*, de modo que cada grano queda como un componente reutilizable sin fondo. Se incluye un mecanismo de *auto-polaridad* que invierte la máscara cuando el borde de la imagen queda marcado como objeto, lo que permite operar con fondo claro u oscuro.

II-B. Generación sintética y ground truth

Antes de componer la escena, cada grano recibe **augmentación a nivel de componente**: transformaciones afines (rotación $\theta \in [0, 360^\circ)$, escala, *flips*) y fotométricas en espacio HSV. Esta aleatorización deliberada de los factores irrelevantes es **domain randomization** [5], cuya hipótesis es que exponer al modelo a suficiente variabilidad simulada lo fuerza a aprender lo invariante (la forma del grano) y reduce la brecha *sim-to-real*.

La escena se compone sobre un lienzo insertando $N \in [20, 150]$ granos. Cada grano se fusiona con la ecuación de composición *over* [4]:

$$I = \alpha F + (1 - \alpha) B, \quad (1)$$

donde F es el grano, B el fondo acumulado y α el canal alfa; esto evita bordes duros (*aliasing*). Para evitar oclusiones totales se mantiene una máscara global de ocupación y se rechaza una ubicación si el solapamiento relativo (derivado de la *Intersection over Union*, $\text{IoU} = |A \cap B| / |A \cup B|$) supera un umbral. **En el mismo paso** en que se ubica un grano se escribe su etiqueta en formato YOLO [*clase*,




Figura 1. Muestras del conjunto de validación sintético con las detecciones del modelo superpuestas: cada grano se detecta con confianza cercana a 1,0.

$x_c, y_c, w, h]$ normalizada: la anotación es **exacta por construcción**, sin intervención humana. Finalmente se aplica un postprocesamiento global (desenfoque gaussiano y ruido de sensor) para unificar la firma óptica de fondo y granos y evitar que la red detecte discontinuidades sintéticas en lugar del objeto.

II-C. Modelo y entrenamiento

Se hace *fine-tuning* de YOLOv8 [2], un detector *one-stage* (predice cajas y clase en una sola pasada, a diferencia de los detectores de dos etapas tipo Faster R-CNN). Se parte de pesos pre-entrenados en COCO (se transfieren 319/355 tensores) y se reentrena con una sola clase (*poroto*). Configuración: entrada 1024×1024 , 80 épocas, optimizador AdamW (selección automática), *mosaic*=0.3 y *flips*, sobre 400 imágenes de entrenamiento y 100 de validación (1685 instancias). El **conteo** es la cantidad de detecciones por encima del umbral de confianza.

II-D. Despliegue

La inferencia se expone como servicio HTTP (FastAPI): el cliente envía una imagen, un módulo ejecuta el modelo, cuenta y devuelve {*success*, *cantidad*}. En paralelo se persiste la *imagen anotada* (cada grano con su contorno e índice numérico) y un archivo de metadatos (id, *timestamp*, versión del modelo, conteo y confianza). La bandera *success* se baja cuando la confianza promedio cae por debajo de un umbral, señalando que conviene revisión humana (Fig. 2).

III. RESULTADOS EXPERIMENTALES Y ANÁLISIS

La Tabla I resume los resultados sobre el conjunto de validación (in-distribution). Como línea de base sin entrenamiento

Cuadro I
RESULTADOS EN VALIDACIÓN (100 IMÁGENES, 1685 INSTANCIAS)

Método	mAP@.5	mAP@.5:.95	MAE	Lat.	Params
Watershed (base)	—	—	6.5	—	—
YOLOv8n	0.995	0.979	0.00	13 ms	3.0 M
YOLOv8s	0.995	0.982	0.00	14 ms	11.1 M

Validación in-distribution; el conteo satura (MAE=0) en ambos modelos. Se prioriza nano por tamaño (6 vs 22 MB) ante exactitud equivalente.

se incluye un detector clásico (segmentación + *watershed*). La Fig. 1 muestra detecciones representativas del modelo sobre el conjunto de validación.

El detector clásico alcanza un **MAE de 6.5 granos** (MAPE $\approx 6\%$): cuenta bien en baja densidad y **subcuenta** cuando los granos se tocan, porque el *watershed* fusiona instancias adyacentes. El modelo entrenado YOLOv8n logra **mAP@0.5 = 0.995**, **mAP@0.5:0.95 = 0.979** y **MAE = 0** en conteo, con ~ 13 ms de inferencia por imagen y 3.0 M de parámetros; el entrenamiento completo (80 épocas) tomó ~ 15 min en una GPU NVIDIA T4. El modelo *small* alcanza el mismo mAP@0.5 (0.995) y MAE (0), con un mAP@0.5:0.95 marginalmente superior (0.982 vs 0.979), pero con $3.7\times$ más parámetros (11.1 vs 3.0 M; 22 vs 6 MB) y latencia equivalente. Ante una exactitud prácticamente idéntica, se selecciona el **nano** por su menor tamaño, lo que justifica su despliegue.

Análisis crítico. Las métricas casi perfectas se explican porque la validación es **in-distribution**: imágenes sintéticas de la misma distribución del entrenamiento, donde la tarea es relativamente fácil. Este resultado **valida el método y el pipeline** (el detector aprende a localizar y contar de forma confiable a partir de datos auto-etiquetados), pero **no** prueba la generalización a fotografías reales. La validación con imágenes reales etiquetadas —la **brecha sim-to-real**— es el límite honesto de este prototipo. Se observa además degradación en escenas de muy alta densidad por oclusión (cajas superpuestas), donde un enfoque de segmentación de instancias o de mapas de densidad podría aportar mejoras.

¿Por qué composición y no GANs? Frente a generar imágenes con redes generativas, la composición por capas entrega **etiquetas exactas y gratuitas**, control explícito de densidad y oclusión, y evita el riesgo de *mode collapse*; las GAN producen imágenes plausibles pero sin anotación de instancia.

IV. CONCLUSIONES

1. El **cuello de botella de datos** puede resolverse generando un dataset sintético con *ground truth* automático, eliminando la anotación manual.
2. El *fine-tuning* de un detector **pre-entrenado** (YOLOv8) sobre datos sintéticos es suficiente para un conteo confiable en distribución (mAP@0.5=0.995, MAE=0).
3. Para esta tarea, el modelo **nano** iguala en exactitud al *small* y lo supera en tamaño/latencia, por lo que es la mejor opción de despliegue.




Figura 2. Servicio de inferencia sobre una escena compuesta a partir de granos reales: 15 granos detectados con 97,4 % de confianza promedio (success=true). El panel derecho muestra los metadatos estructurados (conteo, confianzas individuales y bandera de calidad) que aportan trazabilidad.

4. Evaluar el **error de conteo** (MAE/MAPE), y no solo el mAP, es clave porque es la métrica alineada con el objetivo de negocio.
5. La principal limitación es la **brecha sim-to-real**: la validación con fotos reales y, eventualmente, un *fine-tuning* mixto sintético+real son el trabajo futuro prioritario.

REFERENCIAS

- [1] W. Lin *et al.*, "Soybean image dataset for classification," *Data in Brief*, vol. 48, 109300, 2023.
- [2] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8," 2023. [Online]. Disponible: <https://github.com/ultralytics/ultralytics>
- [3] N. Otsu, "A threshold selection method from gray-level histograms," *IEEE Trans. Syst., Man, Cybern.*, vol. 9, no. 1, pp. 62–66, 1979.
- [4] T. Porter and T. Duff, "Compositing digital images," *Proc. SIGGRAPH*, pp. 253–259, 1984.
- [5] J. Tobin *et al.*, "Domain randomization for transferring deep neural networks from simulation to the real world," *Proc. IEEE/RSJ IROS*, pp. 23–30, 2017.
- [6] J. Li, R. T. Magar, D. Chen, F. Lin, D. Wang, X. Yin, W. Zhuang, and Z. Li, "SoybeanNet: Transformer-based convolutional neural network for soybean pod counting from Unmanned Aerial Vehicle (UAV) images," *Computers and Electronics in Agriculture*, vol. 220, art. 108861, 2024.
- [7] T. Jiang, M. Shao, T. Zhang, X. Liu, and Q. Yu, "Soybean pod and seed counting in both outdoor fields and indoor laboratories using unions of deep neural networks," *arXiv:2502.15286*, 2025.